

1 Definiciones Clave

Red de Hopfield: Es una red neuronal recurrente de unidades binarias simétricas, diseñada como memoria asociativa. Su dinámica de retroalimentación permite que ciertos estados sean atracciones (patrones almacenados) de la red.

Estado y representación: Sea N el número de neuronas. El estado de la red en un instante se representa como $s = (s_1, \dots, s_N)^T \in \{-1, +1\}^N$ $s = (s_1, \dots, s_N)^T \in \{-1, +1\}^N$ (variante bipolar). El objetivo es que, ante una entrada ruidosa o incompleta, la dinámica genere una salida cercana al patrón almacenado correcto.

Matriz de pesos y umbrales: La red tiene una matriz de pesos simétrica $W = [w_{ij}] \in \mathbb{R}^{N \times N}$ $W = [w_{ij}] \in \mathbb{R}^{N \times N}$ con $w_{ii} = 0$ $w_{ii} = 0$ para todos i . Los umbrales se representan por un vector $\theta = (\theta_1, \dots, \theta_N)^T$ $\theta = (\theta_1, \dots, \theta_N)^T$.

Función de energía: La Hopfield almacena y recupera patrones como mínimos locales de una energía. Para un estado s ,

$$E(s) = -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N w_{ij} s_i s_j - \sum_{i=1}^N \theta_i s_i.$$

$E(s) = -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N w_{ij} s_i s_j - \sum_{i=1}^N \theta_i s_i$. (Con $w_{ii} = 0$ $w_{ii} = 0$, esta expresión

puede escribirse también como $E(s) = -\frac{1}{2} s^T W s - \theta^T s$ $E(s) = -\frac{1}{2} s^T W s - \theta^T s$.)

Regla de actualización (dinámica): Cada neurona i se actualiza de forma que

$$s_i^{t+1} = \text{sign}(h_i^t), \quad h_i^t = \sum_{j=1}^N w_{ij} s_j^t - \theta_i,$$

si $t+1 = \text{sign}(h_i^t)$, $h_i^t = \sum_{j=1}^N w_{ij} s_j^t - \theta_i$, donde $\text{sign}(x) = +1$ si

$x \geq 0$ $x \geq 0$ y -1 si $x < 0$ $x < 0$. La actualización puede ser asincrónica (una neurona a la vez en un orden) o sincrónica (todas a la vez). En Hopfield, la actualización asincrónica garantiza la no-umento de la energía y convergencia a un punto estacionario.

Aprendizaje (regla de Hebb): Para almacenar un conjunto de patrones $\{\xi^\mu\}_{\mu=1}^p$ $\{\xi^\mu\}_{\mu=1}^p$ con $\xi^\mu \in \{-1, +1\}^N$ $\xi^\mu \in \{-1, +1\}^N$, la regla de aprendizaje de Hopfield es

$$w_{ij} = \frac{1}{N} \sum_{\mu=1}^p \xi_i^\mu \xi_j^\mu, \quad i \neq j, \quad w_{ii} = 0.$$

$w_{ij} = \frac{1}{N} \sum_{\mu=1}^p \xi_i^\mu \xi_j^\mu$, $i \neq j$, $w_{ii} = 0$. Si se añaden umbrales, pueden

incorporarse como θ_i θ_i que se ajustan de modo similar o se incorporan al término lineal.

Capacidad y estabilidad: En el régimen de grandes NN y patrones aleatorios, la capacidad de almacenamiento sin confundir patrones es aproximadamente

$$\alpha_c = \frac{p_c}{N} \approx 0.138,$$

$\alpha_c = N p_c \approx 0.138$, es decir, se pueden almacenar aproximadamente $p_c \approx 0.138 N p_c$

$\approx 0.138 N$ patrones sin que la mayoría de ellos pierda su estabilidad. Más allá de esta capacidad, aparecen estados espurios y los patrones almacenados pueden volverse inestables.

Patrón estable y atracciones: Un patrón ξ^μ es estable si, al evaluarlo como estado, la actualización con la regla anterior mantiene el estado (o lo lleva de vuelta a él). En ese caso, ξ^μ es un mínimo local de la energía.

Convergencia y ruido: La red converge a una de las memorias almacenadas cuando el estado inicial está en la cuenca de atracción de esa memoria. Pequeños ruidos pueden ser corregidos por la atracción de la memoria correspondiente; ruidos grandes pueden conducir a estados espurios o a otros patrones almacenados.

2 Explicaciones Detalladas

2.1 Tema 1: Fundamentos de la dinámica y la energía

La Hopfield es una red recurrente con activa retroalimentación. Su función de energía garantiza que, con actualizaciones asincrónicas, E nunca aumenta: - Dado un estado s y una neurona i a actualizar, el nuevo estado s'_i satisface $E(s') \leq E(s)$. - La actualización de una neurona cambia la energía en función de la diferencia entre el estado anterior y el nuevo:

$$E(s') - E(s) = -\frac{1}{2}(s'_i - s_i) \sum_j w_{ij} s_j - (s'_i - s_i) \theta_i.$$

$E(s') - E(s) = -\frac{1}{2}(s'_i - s_i) \sum_j w_{ij} s_j - (s'_i - s_i) \theta_i$. Como $s'_i = \text{sign}(h_i^t)$ $s'_i = \text{sign}(h_i^t)$ con

$h_i^t = \sum_j w_{ij} s_j^t - \theta_i$ $h_i^t = \sum_j w_{ij} s_j^t - \theta_i$, se puede demostrar que

$$(s'_i - s_i) h_i^t \geq 0 \Rightarrow E(s') \leq E(s),$$

$(s'_i - s_i) h_i^t \geq 0 \Rightarrow E(s') \leq E(s)$, asegurando la convergencia hacia mínimos locales de la energía.

Importancia de la simetría y la no-autoconexión: la simetría de W ($w_{ij} = w_{ji}$) y la condición $w_{ii} = 0$ son cruciales para que la energía esté bien definida y para que la dinámica tenga atracciones estables. Sin estas condiciones, la convergencia puede fallar.

Convergencia y estabilidad de memorias: si un patrón está suficientemente separado en el espacio de estados y la capacidad no se excede, la red convergerá de estados iniciales cercanos a ese patrón hacia dicho patrón como mínimo de energía.

2.2 Tema 2: Aprendizaje, capacidad y limitaciones

Regla de Hebb para Hopfield: al superponer los productos de las señales de neuronas para cada patrón, la red se configura para que esos patrones sean atracciones de la dinámica. El factor $1/N$ ayuda a mantener la energía en rangos manejables y facilita la estabilidad.

Capacidad y espurios: a medida que se añaden más patrones, aparecen estados espurios (no correspondientes a ningún patrón almacenado) que pueden confundirse con memorias. La relación de capacidad $\alpha_c \approx 0.138$ es una aproximación teórica para grandes N y patrones aleatorios; en la práctica, la capacidad efectiva puede verse afectada por la estructura de los patrones y por la presencia de umbrales distintos de cero.

Variantes y consideraciones prácticas: - Umbrales no nulos ($\theta_i \neq 0$) pueden aumentar la capacidad utilizable para ciertos conjuntos de patrones y ayudar a controlar la asimetría en la distribución de la actividad. - Patrones no binarios o con codificación distinta pueden requerir adaptaciones de la dinámica o de la función de energía. - Versiones continuas o cuasi-continuas (redes de Hopfield con neuronas de activación suave) introducen conceptos como estabilidad en dominios continuos y conectividad ponderada.

Relación con otras técnicas de memoria: las Hopfield son modelos de memoria asociativa recurrente simples, útiles para entender conceptos de atractores, energía y recuperación de patrones. Sirven como base para entender redes recurrentes más complejas y modelos de memoria basados en energía.

3 Ejemplos y Aplicaciones

• •

Ejemplo 1 (Construcción de pesos y verificación de estabilidad): Sea $N = 4$ y se desean almacenar dos patrones:

$$\xi^1 = \begin{pmatrix} 1 \\ 1 \\ -1 \\ -1 \end{pmatrix}, \quad \xi^2 = \begin{pmatrix} 1 \\ -1 \\ 1 \\ -1 \end{pmatrix}.$$

$\xi^1 = [1 \ 1 \ -1 \ -1]^T$, $\xi^2 = [1 \ -1 \ 1 \ -1]^T$. Usando la regla de Hebb con $N = 4$

$N = 4$ y $w_{ii} = 0$,

$$w_{ij} = \frac{1}{4} \sum_{\mu=1}^2 \xi_i^\mu \xi_j^\mu, \quad i \neq j.$$

$w_{ij} = \frac{1}{4} \sum_{\mu=1}^2 \xi_i^\mu \xi_j^\mu$, $i = j$. El resultado (orden de filas y columnas

consistente con $i < j$ es:

$$W = \begin{pmatrix} 0 & 0 & 0 & -\frac{1}{2} \\ 0 & 0 & -\frac{1}{2} & 0 \\ 0 & -\frac{1}{2} & 0 & 0 \\ -\frac{1}{2} & 0 & 0 & 0 \end{pmatrix}.$$

$W = \left(\begin{array}{c} 000-2100-2100-2100-21000 \end{array} \right)$. Verificación de estabilidad: - Para ξ^1

ξ^1 , con $s = \xi^1 s = \xi^1$, se obtiene $h_1 = 0.5$, $h_2 = 0.5$, $h_3 = -0.5$, $h_4 = -0.5h_1 = 0.5$, $h_2 = 0.5$, $h_3 = -0.5$, $h_4 = -0.5$ y $\text{sign}(h_i) = s_i \text{sign}(h_i) = s_i$ para todos i ; por tanto, $\xi^1 \xi^1$ es punto fijo. - Para $\xi^2 \xi^2$, con $s = \xi^2 s = \xi^2$, se obtiene $h_1 = 0.5$, $h_2 = -0.5$, $h_3 = 0.5$, $h_4 = -0.5h_1 = 0.5$, $h_2 = -0.5$, $h_3 = 0.5$, $h_4 = -0.5$ y $\text{sign}(h_i) = s_i \text{sign}(h_i) = s_i$ para todos i ; por tanto, $\xi^2 \xi^2$ es también punto fijo. Este ejemplo ilustra cómo la regla de aprendizaje puede generar memorias estables y qué implica la capacidad en un caso pequeño.

• •

Ejemplo 2 (Denoising o recuperación): Tomemos la misma red de ejemplo y una versión ruidosa de $\xi^1 \xi^1$:

$$s^{(0)} = \begin{pmatrix} -1 \\ 1 \\ -1 \\ -1 \end{pmatrix},$$

$s(0) = \left(\begin{array}{c} -11-1-1 \end{array} \right)$, que difiere de $\xi^1 \xi^1$ en la primera componente. Aplicando

actualizaciones asincrónicas (p. ej., en el orden 1,2,3,4 repetidamente), la red tiende a recuperar $\xi^1 \xi^1$ como memoria estable. Este comportamiento ilustra la propiedad de denoising (corrección de ruido) de las Hopfield cuando el número de patrones almacenados se mantiene por debajo de la capacidad teórica.

• •

Aplicaciones y límites prácticos: - Memoria asociativa: recuperación de patrones a partir de entradas incompletas o ruidosas. - Demostraciones didácticas de conceptos de energía, atracciones y estabilidad en redes neuronales. - Limitaciones: capacidad finita, presencia de espurios a medida que p se acerca a p_c , sensibilidad a la distribución de patrones y a umbrales.

4 Puntos Importantes a Recordar

• •

Las Hopfield son redes de memoria asociativa basadas en energía. Los patrones aprendidos corresponden a mínimos locales de la energía.

- •

La simetría de la matriz de pesos y la ausencia de autoconexión ($w_{ii} = 0$) son clave para la convergencia de la dinámica.

- •

La actualización asincrónica garantiza que la energía no aumente en cada paso, asegurando convergencia a un mínimo local.

- •

La capacidad de almacenamiento está limitada en función de N : aproximadamente $p_c \approx 0.138N$ para patrones aleatorios; superar esa capacidad aumenta la probabilidad de espurios y fallo de recuperación.

- •

Los umbrales (θ_i) pueden modular la actividad y afectar la capacidad y la estabilidad de ciertas memorias.

- •

Las redes de Hopfield en esencia están diseñadas para recuperación de patrones: se recuperan entradas ruidosas que se parezcan a memorias almacenadas, funcionando como una memoria de tipo attractor.