

Material de Estudio de Redes Neuronales - Redes de Hopfield

Redes Neuronales - Material de Estudio

```
\documentclass[11pt]{article}
\usepackage[utf8]{inputenc}
\usepackage[T1]{fontenc}
\usepackage[spanish]{babel}
\usepackage[a4paper,margin=2.5cm]{geometry}
\usepackage{hyperref}
\usepackage{amsmath,amssymb}
\usepackage{enumitem}
\setlist{leftmargin=*}
\hypersetup{colorlinks=true,linkcolor=blue,urlcolor=blue}

\title{Notas de Estudio: Redes de Hopfield}
\date{}

\begin{document}
\maketitle

\section{Definiciones Clave}

\textbf{Red de Hopfield}: Es una red neuronal recurrente de unidades binarias simétricas, diseñada como memoria asociativa. Su dinámica de retroalimentación permite que ciertos estados sean atracciones (patrones almacenados) de la red.

\textbf{Estado y representación}: Sea  $N$  el número de neuronas. El estado de la red en un instante se representa como  $\mathbf{s} = (s_1, \dots, s_N)^T \in \{-1, +1\}^N$  (variante bipolar). El objetivo es que, ante una entrada ruidosa o incompleta, la dinámica genere una salida cercana al patrón almacenado correcto.

\textbf{Matriz de pesos y umbrales}: La red tiene una matriz de pesos simétrica  $W = [w_{ij}] \in \mathbb{R}^{N \times N}$  con  $w_{ii}=0$  para todos  $i$ . Los umbrales se representan por un vector  $\boldsymbol{\theta} = (\theta_1, \dots, \theta_N)^T$ .

\textbf{Función de energía}: La Hopfield almacena y recupera patrones como mínimos locales de una energía. Para un estado  $\mathbf{s}$ ,
```

\$\$

$$E(\mathbf{s}) = -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N w_{ij} s_i s_j - \sum_{i=1}^N \theta_i s_i.$$

\$\$

(Con $(w_{ii}=0)$, esta expresión puede escribirse también como $(E(\mathbf{s}) = -\frac{1}{2} \mathbf{s}^T \mathbf{W} \mathbf{s} - \boldsymbol{\theta}^T \mathbf{s})$.)

Regla de actualización (dinámica): Cada neurona i se actualiza de forma que

\$\$

$$s_i^{t+1} = \operatorname{sign}(\operatorname{Big}(h_i^t)), \quad$$

$$h_i^t = \sum_{j=1}^N w_{ij} s_j^t - \theta_i,$$

\$\$

donde $\operatorname{sign}(x)=+1$ si $(x \geq 0)$ y (-1) si $(x < 0)$. La actualización puede ser **asincrónica** (una neurona a la vez en un orden) o **sincrónica** (todas a la vez). En Hopfield, la actualización asincrónica garantiza la no-umento de la energía y convergencia a un punto estacionario.

Aprendizaje (regla de Hebb): Para almacenar un conjunto de patrones

$(\{\mathbf{x}^{\mu}\}_{\mu=1}^p)$ con $(\mathbf{x}^{\mu} \in \{-1,+1\}^N)$, la regla de aprendizaje de Hopfield es

\$\$

$$w_{ij} = \frac{1}{N} \sum_{\mu=1}^p x_i^{\mu} x_j^{\mu}, \quad i \neq j, \quad w_{ii}=0.$$

\$\$

Si se añaden umbrales, pueden incorporarse como (θ_i) que se ajustan de modo similar o se incorporan al término lineal.

Capacidad y estabilidad: En el régimen de grandes (N) y patrones aleatorios, la capacidad de almacenamiento sin confundir patrones es aproximadamente

\$\$

$$\alpha_c = \frac{p_c}{N} \approx 0.138,$$

\$\$

es decir, se pueden almacenar aproximadamente $(p_c \approx 0.138 N)$ patrones sin que la mayoría de ellos pierda su estabilidad. Más allá de esta capacidad, aparecen estados espurios y los patrones almacenados pueden volverse inestables.

Patrón estable y atracciones: Un patrón $(\mathbf{x}^{\mu})$ es estable si, al evaluarlo como estado, la actualización con la regla anterior mantiene el estado (o lo lleva de vuelta a él). En ese caso, $(\mathbf{x}^{\mu})$ es un mínimo local de la energía.

Convergencia y ruido: La red converge a una de las memorias almacenadas cuando el estado inicial está en la cuenca de atracción de esa memoria. Pequeños ruidos pueden ser corregidos por la atracción de la memoria correspondiente; ruidos grandes pueden conducir a estados espurios o a otros patrones almacenados.

\section{Explicaciones Detalladas}

\subsection{Tema 1: Fundamentos de la dinámica y la energía}

La Hopfield es una red recurrente con activa retroalimentación. Su función de energía garantiza que, con actualizaciones asincrónicas, E nunca aumenta:

- Dado un estado $\mathbf{s}$ y una neurona i a actualizar, el nuevo estado $\mathbf{s}'$ satisface $E(\mathbf{s}') \leq E(\mathbf{s})$.

- La actualización de una neurona cambia la energía en función de la diferencia entre el estado anterior y el nuevo:

$$E(\mathbf{s}') - E(\mathbf{s}) = -\frac{1}{2} (s'_i - s_i) \sum_j w_{ij} s_j - (s'_i - s_i) \theta_i$$

Como $(s'_i - s_i) = \text{sign}(h_i)$ con $(h_i = \sum_j w_{ij} s_j - \theta_i)$, se puede demostrar que

[

$$(s'_i - s_i) h_i \geq 0 \quad \Rightarrow \quad E(\mathbf{s}') \leq E(\mathbf{s}),$$

]

asegurando la convergencia hacia mínimos locales de la energía.

Importancia de la simetría y la no-autoconexión: la simetría de (W) ($w_{ij} = w_{ji}$) y la condición $w_{ii} = 0$ son cruciales para que la energía esté bien definida y para que la dinámica tenga atracciones estables. Sin estas condiciones, la convergencia puede fallar.

Convergencia y estabilidad de memorias: si un patrón está suficientemente separado en el espacio de estados y la capacidad no se excede, la red convergerá de estados iniciales cercanos a ese patrón hacia dicho patrón como mínimo de energía.

\subsection{Tema 2: Aprendizaje, capacidad y limitaciones}

Regla de Hebb para Hopfield: al superponer los productos de las señales de neuronas para cada patrón, la red se configura para que esos patrones sean atracciones de la dinámica. El factor $(1/N)$ ayuda a mantener la energía en rangos manejables y facilita la estabilidad.

Capacidad y espurios: a medida que se añaden más patrones, aparecen estados espurios (no correspondientes a ningún patrón almacenado) que pueden confundirse con memorias. La relación de capacidad $(\alpha_c \approx 0.138)$ es una aproximación teórica para grandes (N) y patrones aleatorios; en la práctica, la capacidad efectiva puede verse afectada por la estructura de los patrones y por la presencia de umbrales distintos de cero.

Variantes y consideraciones prácticas:

- Umbrales no nulos $(\theta_i \neq 0)$ pueden aumentar la capacidad utilizable para ciertos conjuntos de patrones y ayudar a controlar la asimetría en la distribución de la actividad.

- Patrones no binarios o con codificación distinta pueden requerir adaptaciones de la dinámica o de la función de energía.

- Versiones continuas o cuasi-continuas (redes de Hopfield con neuronas de activación suave) introducen conceptos como estabilidad en dominios continuos y conectividad ponderada.

Relación con otras técnicas de memoria: las Hopfield son modelos de memoria asociativa recurrente simples, útiles para entender conceptos de atractores, energía y recuperación de patrones. Sirven como base para entender redes recurrentes más complejas y modelos de memoria basados en energía.

Ejemplos y Aplicaciones

Ejemplo 1 (Construcción de pesos y verificación de estabilidad):

Sea $(N=4)$ y se desean almacenar dos patrones:

[

$$\mathbf{x}^1 = \begin{pmatrix} 1 \\ 1 \\ -1 \\ -1 \end{pmatrix}, \quad$$

$$\mathbf{x}^2 = \begin{pmatrix} 1 \\ -1 \\ 1 \\ -1 \end{pmatrix}.$$

]

Usando la regla de Hebb con $(N=4)$ y $(w_{ii}=0)$,

[

$$w_{ij} = \frac{1}{4} \sum_{\mu=1}^2 x_i^{\mu} x_j^{\mu}, \quad i \neq j.$$

]

El resultado (orden de filas y columnas consistente con $(i < j)$) es:

[

$$W = \begin{pmatrix}$$

$$0 & 0 & 0 & -\frac{1}{2} \\$$

$$0 & 0 & -\frac{1}{2} & 0 \\$$

$$0 & -\frac{1}{2} & 0 & 0 \\$$

$$-\frac{1}{2} & 0 & 0 & 0$$

$$\end{pmatrix}.$$

]

Verificación de estabilidad:

- Para $(\mathbf{x}^1)$, con $(\mathbf{s} = \mathbf{x}^1)$, se obtiene

$(h_1 = 0.5, h_2 = 0.5, h_3 = -0.5, h_4 = -0.5)$ y $(\text{sign}(h_i) = s_i)$ para todos (i) ; por tanto, $(\mathbf{x}^1)$ es punto fijo.

- Para $(\mathbf{x}^2)$, con $(\mathbf{s} = \mathbf{x}^2)$, se obtiene

$(h_1=0.5, h_2=-0.5, h_3=0.5, h_4=-0.5)$ y $(\text{sign}(h_i)=s_i)$ para todos i ; por tanto, $\mathbf{x}^2$ es también punto fijo.

Este ejemplo ilustra cómo la regla de aprendizaje puede generar memorias estables y qué implica la capacidad en un caso pequeño.

Ejemplo 2 (Denoising o recuperación): Tomemos la misma red de ejemplo y una versión ruidosa de $\mathbf{x}^1$:

[

$\mathbf{s}^{(0)} = \begin{pmatrix} -1 \\ 1 \\ -1 \\ -1 \end{pmatrix}$,

]

que difiere de $\mathbf{x}^1$ en la primera componente. Aplicando actualizaciones asincrónicas (p. ej., en el orden 1,2,3,4 repetidamente), la red tiende a recuperar $\mathbf{x}^1$ como memoria estable. Este comportamiento ilustra la propiedad de denoising (corrección de ruido) de las Hopfield cuando el número de patrones almacenados se mantiene por debajo de la capacidad teórica.

Aplicaciones y límites prácticos:

- Memoria asociativa: recuperación de patrones a partir de entradas incompletas o ruidosas.
- Demostraciones didácticas de conceptos de energía, atracciones y estabilidad en redes neuronales.
- Limitaciones: capacidad finita, presencia de espurios a medida que p se acerca a p_c , sensibilidad a la distribución de patrones y a umbrales.

Puntos Importantes a Recordar

Las Hopfield son redes de memoria asociativa basadas en energía. Los patrones aprendidos corresponden a mínimos locales de la energía.

La simetría de la matriz de pesos y la ausencia de autoconexión ($w_{ii}=0$) son clave para la convergencia de la dinámica.

La actualización asincrónica garantiza que la energía no aumente en cada paso, asegurando convergencia a un mínimo local.

La capacidad de almacenamiento está limitada en función de N : aproximadamente $p_c \approx 0.138N$ para patrones aleatorios; superar esa capacidad aumenta la probabilidad de espurios y fallo de recuperación.

Los umbrales (θ_i) pueden modular la actividad y afectar la capacidad y la estabilidad de ciertas memorias.

Las redes de Hopfield en esencia están diseñadas para recuperación de patrones: se recuperan entradas ruidosas que se parezcan a memorias almacenadas, funcionando como una memoria de tipo attractor.

\end{itemize}

\end{document}